Estatística Bayesiana

Jose Storopoli
josees@uni9.pro.br Universidade Nove de Julho - UNINOVE

Sumário

1. Estatística Bayesiana
2. Distribuições Probabilísticas
3. `rstanarm` e `brms`
4. Priors
5. Markov Chain Monte Carlo - MCMC
6. Regressão Linear Bayesiana
7. Regressão Logística Bayesiana
8. Regressão de Poisson Bayesiana
9. Regressão Robusta Bayesiana
10. Modelos Multiníveis Bayesianos
11. Comparação de Modelos
12. Referências

Sumário para Estatística Bayesiana

1.1 Leituras Recomendadas

1.2 O que é Estatística Bayesiana

1.2.1 O que muda da Estatística Frequentista?

1.3 Ferramentas

1.3.1 Stan

1.3.2 R

1.3.3 Python

1.3.4 Julia

1.4 Probabilidade

1.4.1 O que é Probabilidade?

1.4.2 Teorema de Bayes

1.5 Estatística Frequentista versus Bayesiana

1.5.1 O que são p-valores e Intervalos de Confiança

1.6 Estatística Bayesiana

1.6.1 Vantagens da Estatísca Bayesiana

Estatística Bayesiana - Leituras Recomendadas

- Gelman et al. (2013) - Capítulo 1: Probability and inference
- McElreath (2020) - Capítulo 1: The Golem of Prague
- Gelman, Hill et al. (2020) - Capítulo 3: Some basic methods in mathematics and probability
- Storopoli (2021) - O que é Estatística Bayesiana?
- **Probabilidade**:
  - Um ótimo livro-texto - Bertsekas e Tsitsiklis (2008)
  - Um ótimo livro-texto (pule a parte de estatística frequentista) - Dekking et al. (2010)
  - Do ponto de vista Bayesiano e com abordagem filosófica - Jaynes (2003)
  - Do ponto de vista Bayesiano e com abordagem simples e lúdica - Kurt (2019)
  - Abordagem filosófica e uma exposição não focada no rigor matemático - Diaconis e Skyrms (2019)

O que é Estatística Bayesiana

A estatística Bayesiana[1] é uma abordagem de análise de dados baseada no teorema de Bayes, onde o conhecimento disponível sobre os parâmetros em um modelo estatístico é atualizado com as informações dos dados observados (Gelman et al., 2013). O conhecimento prévio é expresso como uma distribuição *a priori*[2] e combinado com os dados observados na forma de uma função de verossimilhança[3] para determinar a distribuição *a posteriori* [4] A *posteriori* também pode ser usada para fazer previsões sobre eventos futuros.

[1] maiúsculo, pois se refere ao teorema de Bayes que é um sobrenome
[2] do inglês *prior distribution*
[3] do inglês *likelihood function*
[4] do inglês *posterior distribution*

O que muda da Estatística Frequentista?

- **Flexibilidade** - peças probabilísticas para construir um modelo[5]:
  - Conjecturas probabilísticas sobre os parâmetros:
    - *Priori*
    - Verossimilhança
- Melhor tratamento da **incerteza**:
  - Coerência
  - Propagação
  - Não se usa *"se amostrássemos infinitamente de uma população que não existe..."*
- Sem p**-valores**:
  - Todas as intuições estatísticas fazem **sentido**
  - 95% de certeza que o valor do parâmetro θ está entre x e y
  - Quase **impossível** fazer p-hacking.

[5] como se fosse LEGO

Um pouco mais de Formalidade

- Estatística Bayesiana usa declarações probabilísticas:
  - um ou mais parâmetros θ
  - dados não-observados $\tilde{y}$
- Essas declarações são condicionadas nos valores observados de y:
  - $P(\theta \mid y)$
  - $P(\tilde{y} \mid y)$
- Nós também, de maneira implícita, condicionados nos valores observados de quaisquer co-variáveis x

Principal Mudança

Definição (Estatística Bayesiana)

O uso do Teorema de Bayes[6] *como o procedimento de* ***estimativa dos parâmetros de interesse*** θ ***ou dados não-observados*** $\tilde{y}$. *(Gelman et al., 2013)*

[6] mais sobre ele já já...

Ferramentas para Estatística Bayesiana

- Stan
- PyMC
- JAGS
- BUGS

Stan[7]

- Plataforma para modelagem e computação estatística de alto desempenho
- Suporte financeiro da NUMFocus:
  - AWS Amazon
  - Bloomberg
  - Microsoft
  - IBM
  - RStudio
  - Facebook
  - NVIDIA
  - Netflix
- Linguagem própria, similar à C++
- Amostrador *Markov Chain Monte Carlo* (MCMC) em paralelo

[7] Carpenter et al. (2017)

R

- R é uma linguagem criada **por estatísticos para estatísticos**
- Possui um vasto **ecossistema de bibliotecas** e é amplamente usado na **ciência** e em especial nas **ciências aplicadas**
- Quase toda **tese maluca** ou **algoritmo inovador** de Estatística/Probabilidade está no CRAN (Repositório de Pacotes R
- Como linguagem de programação é **horrível**[8]: Recomendo `Julia`

[8] consegue ser um pouco menos pior que `Python`

Python e PyMC

- Python consegue ser um pouco melhor que R
- Mas tem a "tara" dos anos 90 de tudo ser **Orientado à Objetos**
- PyMC (Salvatier et al., 2016):
  - Uma Biblioteca de Estatística Bayesiana com o seu próprio amostrador *Markov Chain Monte Carlo* (MCMC)
  - Também com Suporte financeiro da NUMFocus
  - Amarram o cavalo num barco que afundou há algum tempo: Theano
  - Theano **morreu** mas os desenvolvedores do PyMC fizeram um *fork* no projeto e estão usando-o como *backend*

Julia e Turing

- `Julia` (Bezanson et al., 2017) é uma linguagem relativamente nova, lançada pela primeira vez em 2012, que visa ser de **alto nível** e **rápida**
- Linguagem de tipagem **dinâmica rápida** que compila *just-in-time* (JIT) em código nativo usando `LLVM`.
- "Roda como C, mas lê como `Python`" (Perkel, 2019), o que significa que é extremamente **rápida**, fácil **prototipagem** e **ler/escrever** código.
- **Multi-paradigma**, combinando recursos de programação **imperativa**, **funcional** e **orientada a objetos**.

Turing

- `Turing` é uma **Linguagem de Programação Probabilística**[9] escrita totalmente em `Julia`
- Usa **pacotes** de `Julia` para:
  - **Diferenciação Automática**[10]
  - **Distribuições Probabilísticas**
  - **Solucionadores de Equações Ordinais**[11]
  - **Redes Neurais** (sendo responsável pela parte "Bayesiana" da Rede Neural Bayesiana)

[9] em inglês *probabilistic programming language* (PPL)
[10] *autodiff*
[11] *Ordinary Differential Equation Solvers* (ODE)

PROBABILIDADE NÃO EXISTE![12]

- Sim, a probabilidade não existe.
- Ou melhor, probabilidade como uma quantidade física, chance objetiva, **NÃO existe**
- se dispensarmos a questão da chance objetiva *nada se perde*
- A matemática do raciocínio indutivo permanece **exatamente a mesma**

[12] de Finetti (1974)

PROBABILIDADE NÃO EXISTE![13]

- Considere jogar uma moeda de enviesada
- As tentativas são consideradas independentes e, como resultado, exibem outra propriedade importante: **a ordem não importa**
- A frequência é considerada uma **estatística suficiente**
- Dizer que a ordem não importa ou dizer que a única coisa que importa é a frequência são duas maneiras de dizer exatamente a mesma coisa
- Dizemos que essa probabilidade é **invariante sob permutações**

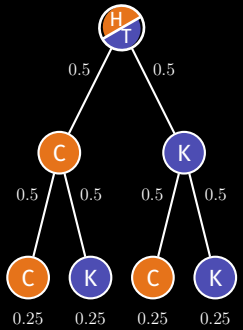

[13] de Finetti (1974)

Interpretações da Probabilidade

- **Objetiva** - frequência no longo prazo de um evento específico
  - $P(\text{chuva}) = \frac{\text{dias que choveram}}{\text{dias totais}}$
  - $P(\text{chance de eu ser presidente} = 0)$ (Nunca ocorreu)

- **Subjetiva** - nível de crença em um evento
  - $P(\text{chuva}) = \text{crença que choverá}$
  - $P(\text{chance de eu ser presidente} = 10^{-10})$ (Muito improvável)

O que é Probabilidade?

Definição (Probabilidade)

Sobre notação, definimos que A é um evento e $P(A)$ a probabilidade do evento, logo:

$$\{P(A) \in \mathbb{R} : 0 \leq P(A) \leq 1\}.$$

Isto quer dizer o "probabilidade do evento A ocorrer é o conjunto de todos os números reais entre 0 e 1; incluindo 0 e 1"

Axiomas da Probabilidade[14]

- **Não-negatividade**: Para todo A, $P(A) \geq 0$. Toda probabilidade é positiva (maior ou igual a zero), independente do evento
- **Aditividade**: Para dois *mutuamente exclusivos* A e B (não podem ocorrer ao mesmo tempo): $P(A) = 1 - P(B)$ e $P(B) = 1 - P(A)$
- **Normalização**: A probabilidade de todos os eventos possíveis $A_1, A_2, \ldots$ devem somar 1: $\sum_{n \in \mathbb{N}} A_n = 1$

[14] Kolmogorov (1933)

Espaços Amostrais

- Discretos

$$\Theta = \{1, 2, \ldots, \}$$

- Contínuos

$$\Theta \in (-\infty, \infty)$$

Espaços Amostrais Discretos

8 Planetas do Nosso Sistema Solar

- Mercúrio - ☿
- Vênus - ♀
- Terra - ♁
- Marte ♂
- Júpiter - ♃
- Saturno ♄
- Urano - ♅
- Netuno ♆

Espaços Amostrais Discretos

O planeta possui campo magnético

$\theta \in E_1$

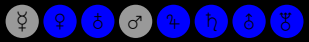

O planeta possui luas

$\theta \in E_2$

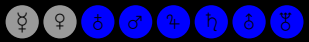

O planeta possui campo magnético e luas

$\theta \in E_1 \cap E_2$

O planeta possui campo magnético ou luas

$\theta \in E_1 \cup E_2$

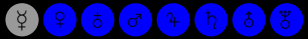

O planeta não possui um campo magnético

$\theta \in \neg E_1$

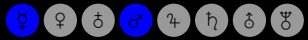

Espaços Amostrais Contínuos

A distância é menos que cinco centímetros

$\theta \in E_1$

A distância é entre três e sete centímetros

$\theta \in E_2$

A distância é menos que cinco centímetros
e entre três e sete centímetros

$\theta \in E_1 \cap E_2$

A distância é menos que cinco centímetros
ou entre três e sete centímetros

$\theta \in E_1 \cup E_2$

A distância não é menos que cinco centímetros

$\theta \in \neg E_1$

Parâmetros Discretos versus Contínuos

Tudo o que foi exposto até agora partiu do pressuposto que os parâmetros são discretos. Isto foi feito com o intuito de prover uma melhor intuição do que é probabilidade. Nem sempre trabalhamos com parâmetros discretos. Os parâmetros podem ser contínuos, como por exemplo: idade, altura, peso etc. Mas não se desespere, todas as regras e axiomas da probabilidade são válidos também para parâmetros contínuos. A única coisa que temos que fazer é trocar todas as somas $\sum$ por integrais $\int$. Por exemplo o terceiro axioma de **Normalização** para variáveis aleatórias contínuas se torna:

$$\int_{x \in X} p(x)dx = 1.$$

Probabilidade Condicional

Definição (Probabilidade Condicional)

Probabilidade de um evento ocorrer caso outro tenha ocorrido ou não.

A notação que usamos é $P(A \mid B)$, que
lê-se como "a probabilidade de observamos A dado que já observamos B".

$$P(A \mid B) = \frac{\textit{número de elementos em } A \textit{ e } B}{\textit{número de elememento s em } B}$$

$$P(A \mid B) = \frac{P(A \cap B)}{(B)}$$

Exemplo de Probabilidade Condicional

Exemplo (Poker Texas Hold'em)

- ***Espaço Amostral***: 52 *cartas no baralho,* 13 *tipos de cartas e* 4 *tipos de naipes.*
- $P(A)$: *Chance de receber um Ás* $\left(\frac{4}{52} = \frac{1}{13}\right)$
- $P(K)$: *Chance de receber um Rei (K)* $\left(\frac{4}{52} = \frac{1}{13}\right)$
- $P(A \mid K)$: *Chance de receber um Ás, dado que você recebeu um Rei (K)* $\left(\frac{4}{51} \approx 0.078\right)$
- $P(K \mid A)$: *Chance de receber um Rei (K), dado que você recebeu um Ás* $\left(\frac{4}{51} \approx 0.078\right)$

Cuidado! Nem sempre $P(A \mid B) = P(B \mid A)$

No exemplo anterior temos a simetria $P(A \mid K) = P(K \mid A)$, **mas nem sempre isso é verdade**[15]

Exemplo (O Papa é católico)

- $P(\textit{papa})$: *Chance alguém aleatório ser papa, algo bem pequeno, 1 em 8 bilhões* $\left(\frac{1}{8 \cdot 10^9}\right)$
- $P(\textit{católico})$: *Chance alguém aleatório ser católico, 1.34 de 8 bilhões* $\left(\frac{1.34}{8} \approx 0.17\right)$
- $P(\textit{católico} \mid \textit{papa})$: *Chance do Papa ser católico* $\left(\frac{999}{1000} = 0.999\right)$
- $P(\textit{papa} \mid \textit{católico})$: *Chance de alguém católico ser o papa* $\left(\frac{1}{1.34 \cdot 10^9} \cdot 0.999 \approx 7.46 \cdot 10^{-10}\right)$
- ***Logo***: $P(\textit{católico} \mid \textit{papa}) \neq P(\textit{papa} \mid \textit{católico})$

[15] Mais especificamente, se as taxas basais $P(A)$ e $P(B)$ não são iguais, a simetria é quebrada $P(A \mid B) \neq P(B \mid A)$!

Um clássico da Probabilidade

Exemplo (Monty Hall)

- *Um apresentador de TV lhe apresenta 3 portas*
- *Uma delas tem um prêmio: um carro! As outras tem um bode*
- *Você deve escolher uma porta (que não é aberta)*
- *Nesse momento Monty abre uma das outras duas portas que você não escolheu, revelando que o carro não se encontra nessa porta e revelando um dos bodes*
- *Monty então lhe pergunta "Você quer manter sua escolha de porta ou trocar?"*

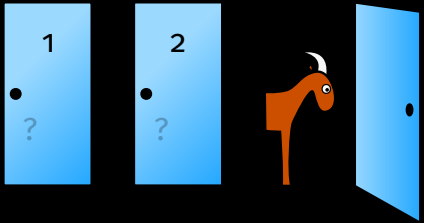

Solução do Problema de Monty Hall

Ideia (Probabilidade de ganhar o carro)

$$P(\textit{carro} \mid C_i) = \frac{1}{3}$$

$$P(\textit{carro}) = \frac{1}{3} \cdot P(\textit{carro} \mid C_1) + \frac{1}{3} \cdot P(\textit{carro} \mid C_2) + \frac{1}{3} \cdot P(\textit{carro} \mid C_3)$$

$$P(\textit{carro}) = \frac{\sum_{i=1}^{3} P(\textit{carro} \mid C_i)}{3}$$

$$P(\textit{carro}) = \frac{1}{3}$$

C_i é o evento no qual o carro está atrás da porta i, $i = 1, 2, 3$

Solução do Problema de Monty Hall[16]

Cenário 1: Não trocar de porta

Simples:

$$\frac{1}{3}$$

Cenário 2: Trocar de porta

Escolha qualquer porta i para ser $C_i = 0$

$$P(\text{carro}) = 0 \cdot P(\text{carro} \mid C_i) + \frac{1}{3} + \frac{1}{3}$$

$$P(\text{carro}) = \frac{2}{3}$$

[16] Se você não acredita nesse resultado veja como simular o problema de Monty Hall nos Slides de Backup no final dessa apresentação

Visualização do Problema de Monty Hall

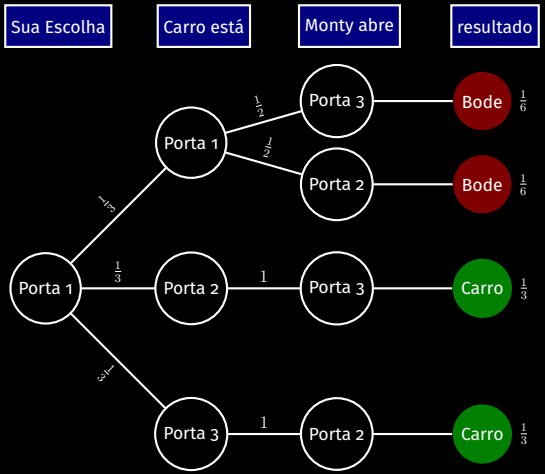

Probabilidade Conjunta

Definição (Probabilidade Conjunta)

Probabilidade de observados dois ou mais eventos ocorrem.

A notação que usamos é $P(A, B)$, que lê-se como "a probabilidade de observamos A e também observamos B".

$$P(A, B) = \text{número de elementos em } A \text{ ou } B$$
$$P(A, B) = P(A \cup B)$$

Exemplo de Probabilidade Conjunta

Exemplo (Revisitando Poker Texas Hold'em)

- ***Espaço Amostral***: 52 *cartas no baralho,* 13 *tipos de cartas e* 4 *tipos de naipes.*
- $P(A)$: *Chance de receber um Ás* $(\frac{4}{52} = \frac{1}{13})$
- $P(K)$: *Chance de receber um Rei (K)* $(\frac{4}{52} = \frac{1}{13})$
- $P(A \mid K)$: *Chance de receber um Ás, dado que você recebeu um Rei (K)* $(\frac{4}{51} \approx 0.078)$
- $P(K \mid A)$: *Chance de receber um Rei (K), dado que você recebeu um Ás* $(\frac{4}{51} \approx 0.078)$
- $P(A, K)$: *Chance de receber um Ás e um Rei (K)*

$$
\begin{aligned}
P(A, K) &= P(K, A) \\
P(A) \cdot P(K \mid A) &= P(K) \cdot P(A \mid K) \\
\frac{1}{13} \cdot \frac{4}{51} &= \frac{1}{13} \cdot \frac{4}{51} \\
&\approx 0.006
\end{aligned}
$$

Visualização de Probabilidade Conjunta vs Probabilidade Condicional

$P(X, Y)$ versus $P(X \mid Y = -0.75)$

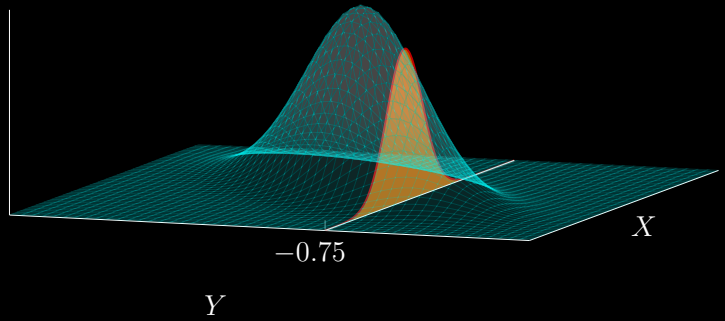

Visualização de Probabilidade Conjunta vs Probabilidade Condicional

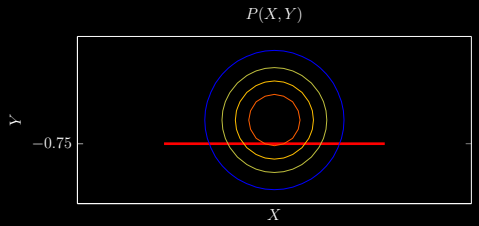

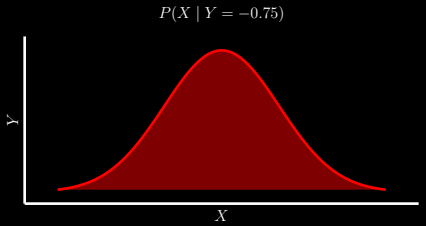

Quem foi Thomas Bayes?

- Thomas Bayes (1701 - 1761) foi um estatístico, filósofo e ministro presbiteriano inglês conhecido por formular um caso específico do teorema que leva seu nome
- Bayes nunca publicou o que se tornaria sua realização mais famosa; suas notas foram editadas e publicadas após sua morte pelo seu amigo Richard Price
- O nome formal do teorema é Bayes-Price-Laplace, pois Thomas Bayes foi o primeiro a descobrir, Richard Price pegou seus rascunhos, formalizou em notação matemática e apresentou para a Royal Society of London, e Pierre Laplace redescobriu o teorema sem ter tido contato prévio no final do século XVIII na França ao usar probabilidade para inferência estatística com dados do Censo na era Napoleônica

Teorema de Bayes

Theorema (Bayes)

Nos diz como "inverter"a probabilidade condicional:

$$P(A \mid B) = \frac{P(A) \cdot P(B \mid A)}{P(B)}$$

Prova do Teorema de Bayes

Lembra que temos a seguinte identidade na probabilidade:

$$P(A, B) = P(B, A)$$
$$P(A) \cdot P(B \mid A) = P(B) \cdot P(A \mid B).$$

Pois bem, agora passe o $P(B)$ do lado direito para o lado esquerdo dividindo:

$$P(A) \cdot P(B \mid A) = \overbrace{P(B)}^{\text{isso vai para} \leftarrow} \cdot P(A \mid B)$$

$$\frac{P(A) \cdot P(B \mid A)}{P(B)} = P(A \mid B)$$
$$P(A \mid B) = \frac{P(A) \cdot P(B \mid A)}{P(B)}$$

Visualização do Teorema de Bayes

Espaço Amostral

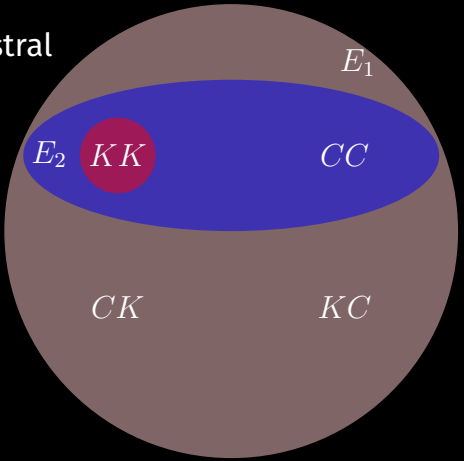

$$E_1 = P(KK \cup CC)$$
$$E_2 = P(KK \mid E_1)$$

Mais um clássico da Probabilidade[17]

Exemplo (Cancêr de Mama)

*O quão acurado é o teste de **câncer de mama**?*

- *1% das mulheres têm **câncer de mama** (Prevalência)*
- *80% das mamografias detectam o **câncer de mama** (Verdadeiro Positivo)*
- *9.6% das mamografias detectam **câncer de mama** quando não há incidência (Falso Positivo)*

$$P(C \mid +) = \frac{P(+ \mid C) \cdot P(C)}{P(+)}$$

$$P(C \mid +) = \frac{P(+ \mid C) \cdot P(C)}{P(+ \mid C) \cdot P(C) + P(+ \mid \neg C) \cdot P(\neg C)}$$

$$P(C \mid +) = \frac{0.8 \cdot 0.01}{0.8 \cdot 0.01 + 0.096 \cdot 0.99}$$

$$P(C \mid +) \approx 0.0776$$

[17] Origem: Yudkowski - *An Intuitive Explanation of Bayes' Theorem*

Porquê o teorema de Bayes é Importante?

Ideia (Podemos Inverter a Probabilidade Condicional)

$$P(\textit{hypothesis} \mid \textit{data}) = \frac{P(\textit{data} \mid \textit{hypothesis})}{P(\textit{data})}$$

Mas isso não é o p-valor? **NÃO!**

O que é o p-valor?

Definição (p-valor)

p-valor é a probabilidade de obter resultados no mínimo tão extremos quanto os que foram observados, dado que a hipótese nula H_0 é verdadeira

$$P(D \mid H_0)$$

O que **não é** o p-valor!

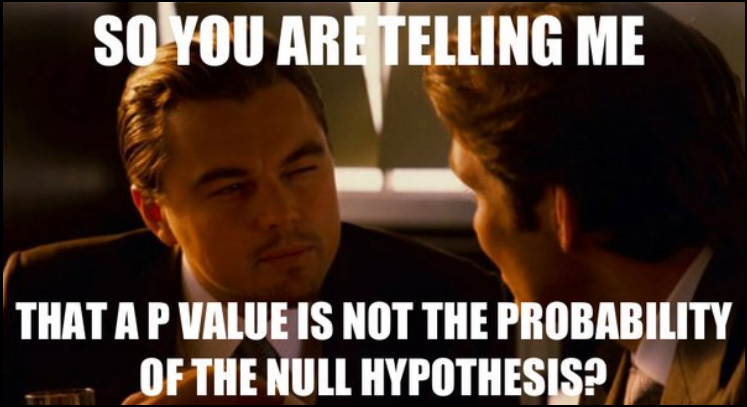

O que **não é** o p-valor!

- **p-valor não é a probabilidade da Hipótese nula** - Famosa confusão entre $P(D \mid H_0)$ e $P(H_0 \mid D)$. Para obter a $P(H_0 \mid D)$ você precisa de estatística Bayesiana.
- **p-valor não é a probabilidade dos dados serem produzidos pelo acaso** - Não! Ninguém falou nada de acaso.
- **p-valor mensura o tamanho do efeito de um teste estatístico** - Também não... p-valor não diz nada sobre o tamanho do efeito. Apenas sobre se o quanto os dados observados divergem do esperado sob a hipótese nula. Além disso, p-valores podem ser "hackeados"de diversas maneiras (Head et al., 2015).

A relação entre p-valor e H_0

Para descobrir o p-valor, **descubra a H_0 que está por trás dele**. Sua definição nunca mudará, pois ela sempre é $P(D \mid H_0)$:

- **Teste t**: $P(D \mid \text{a diferença entre os grupos é zero})$
- **ANOVA**: $P(D \mid \text{não há diferença entre os grupos})$
- **Regressão**: $P(D \mid \text{coeficiente é nulo})$
- **Shapiro-Wilk**: $P(D \mid \text{amostra é normal})$

O que são Intervalos de Confiança?

Definição (Intervalos de Confiança)

Um intervalo de confiança de X% para um parâmetro é um intervalo (a, b) gerado por um procedimento que em amostragem repetida tem uma probabilidade de X% de conter o valor verdadeiro do parâmetro, para todos os valores possíveis do parâmetro

Neyman (1937) (o "pai"dos intervalos de confiança)

O que são Intervalos de Confiança?

Exemplo (Intervalo de Confiança de uma Política Pública)

Digamos que você executou uma análise estatística para comparar eficácia de uma política pública em dois grupos e você obteve a diferença entre a média desses grupos. Você pode expressar essa diferença como um intervalo de confiança. Geralmente escolhemos a confiança de 95%. Isso quer dizer que ***95 estudos de 100****, que usem o* ***mesmo tamanho de amostra e população-alvo****, aplicando o* ***mesmo teste estatístico****, esperarão encontrar um resultado de diferenças de média entre grupos entre o intervalo de confiança.*

Não diz nada sobre a sua **população-alvo**, mas sim sobre a sua **amostra** num processo maluco de **amostragem infinita**...

Intevalos de Confiança versus Intervalos da *Posteriori*

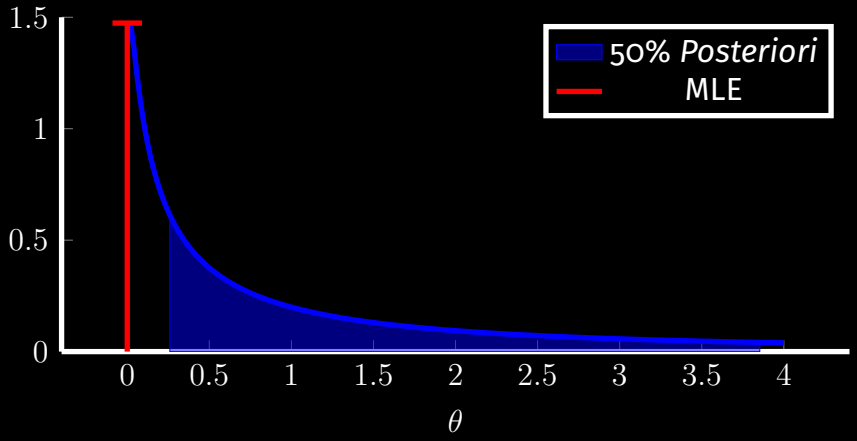

Intevalos de Confiança versus Intervalos da *Posteriori*

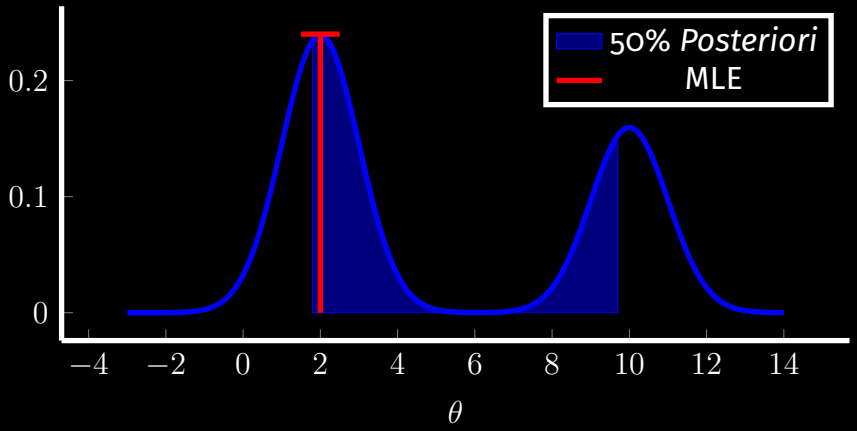

Mas porquê eu nunca vejo estatística sem p-valor?

Não tem como entendermos p-valores se não compreendermos as suas origens e trajetória histórica. A primeira menção do termo foi feita pelo estatístico Ronald Fisher em 1925 (Fisher, 1925):

> *[p-valor é] índice que mede a força da evidência contra a hipótese nula*

- Para quantificar a força da evidência contra a hipótese nula, Fisher defendeu "$p < 0.05$ como um nível padrão para concluir que há evidência contra a hipótese testada"
- "Não seremos frequentemente perdidos se traçarmos uma linha convencional de 0.05"

$p = 0.06$

- Como o p-valor é uma probabilidade, ele é uma quantidade contínua.
- Não há razão para diferenciarmos um p de 0.049 contra um p de 0.051.
- Robert Rosenthal, um psicólogo já dizia "Deus ama p de 0.06 tanto quanto um p de 0.05" (Rosnow & Rosenthal, 1989).

Dentro de todo não Bayesiano há um Bayesiano querendo sair[18]

- No último ano de sua vida, Fisher publicou um artigo (Fisher, 1962) examinando as possibilidades dos métodos Bayesianos, mas com as probabilidades a *priori* a serem determinadas experimentalmente.
- Inclusive alguns autores especulam (Jaynes, 2003) que se Fisher estivesse vivo hoje, ele provavelmente seria um "Bayesiano".

[18] Dennis Lindley "Inside every nonBayesian there is a Bayesian struggling to get out"

Teorema de Bayes como Motor de Inferência

Agora que você já sabe o que é probabilidade e o que é o teorema de Bayes, vou propor o seguinte modelo:

$$\underbrace{P(\theta \mid y)}_{\textit{Posteriori}} = \frac{\overbrace{P(y \mid \theta)}^{\text{Verossimilhança}} \cdot \overbrace{P(\theta)}^{\textit{Priori}}}{\underbrace{P(y)}_{\text{Constante Normalizadora}}}$$

- θ – parâmetro(s) de interesse
- y – dados observados
- ***Priori***: probabilidade prévia do valor do(s) parâmetro(s)
- **Verossimilhança**: probabilidade dos dados observados condicionados aos valores do(s) parâmetro(s)
- ***Posteriori***: probabilidade posterior do valor do(s) parâmetros após observamos os dados y
- **Constante Normalizadora**: $P(y)$ não faz sentido intuitivo. Essa probabilidade é transformada e pode ser interepretada como algo que existe apenas para que o resultado de $P(y \mid \theta)P(\theta)$ seja algo entre 0 e 1 – uma probabilidade válida.

Teorema de Bayes como Motor de Inferência

A estatísica Bayesiana nos permite **quantificar diretamente a incerteza** relacionada ao valor de um ou mais parâmetros do nosso modelo condicionado aos dados observados. Isso é a **característica principal** da estatística Bayesiana. Pois estamos estimando diretamente $P(\theta \mid y)$ por meio do teorema de Bayes. A estimativa resultante é totalmente intuitiva: simplesmente quantifica a intercerteza que temos sobre o valor de um ou mais parâmetro condicionado nos dados, nos pressupostos do nosso modelo (verossimilhança) e na probabilidade prévia que temos sobre tais valores.

Estatística Bayesiana vs Frequentista

	Estatística Bayesiana	Estatística Frequentista
Dados	Fixos — Não Aleatórios	Incertos — Aleatórios
Parâmetros	Incertos — Aleatórios	Fixos — Não Aleatórios
Inferência	Incerteza sobre o valor do parâmetro	Incerteza sobre um processo de amostragem de uma população infinita
Probabilidade	Subjetiva	Objetiva (mas com diversos pressupostos dos modelos)
Incerteza	Intervalo de Credibilidade — $P(\theta \mid y)$	Intervalo de Confiança — $P(y \mid \theta)$

Vantagens da Estatística Bayesiana

- Abordagem Natural para expressar Incerteza
- Habilidade de incorporar Informações Prévias
- Maior Flexibilidade do Modelo
- Distribuição Posterior completa dos Parâmetros
- Propagação Natural da Incerteza

Principal Desvantagem: Velocidade lenta de estimativa de modelos[19]

[19] *e.g.* 30 segundos ao invés de 3 segundos na abordagem frequentista

O começo do fim da Estatística Frequentista

- Saiba que você está em um momento da história no qual a Estatística está passando por grandes mudanças
- Acredito que a estatística frequentista, em especial a maneira que qualificamos evidências e hipóteses com p-valores se transformará de maneira "significante".
- Há cinco anos atrás, a *American Statistical Association* (ASA) publicou uma declaração sobre p-valores (Wasserstein & Lazar, 2016). A declaração diz exatamente o que falamos aqui: Os conceitos principais do teste de significância de hipótese nula e, em particular p-valores não conseguem prover o que os pesquisadores requerem deles. Apesar do que dizem muitos livros de estatística, materiais de ensinos e artigos publicados, p-valores abaixo de 0,05 não "provam"a realidade de nada. Nem, chegando a esse ponto, os p-valores acima de 0,05 refutam alguma coisa.
- A declaração da ASA tem mais de 3.600 citações provocando impacto relevante.

O começo do fim da Estatística Frequentista

- Um simpósio internacional foi promovido em 2017 que originou uma edição especial de acesso aberto da *The American Statistician* dedicada à maneiras práticas de abandonarmos $p < 0.05$ (Wasserstein et al., 2019).
- Logo na sequência vieram mais tentativas e reivindicações. Em setembro de 2017, a *Nature Human Behaviour* publicou um editorial propondo que o nível de significância do p-valor seja reduzido de 0.05 para 0.005 (Benjamin et al., 2018) Diversos autores, inclusive muitos estatísticos altamente influentes e importantes argumentaram que esse simples passo ajudaria a combater o problema da crise de replicabilidade da ciência, que muitos acreditam ser a principal consequência do uso abusivo de p-valores (Ioannidis, 2019).
- Além disso, muitos foram um passo além e sugerem que a ciência descarte de uma vez por todas p-valores («It's Time to Talk about Ditching Statistical Significance», 2019; Lakens et al., 2018). Muitos sugerem (eu inclusive) que a principal ferramenta de inferência seja a estatística Bayesiana (Amrhein et al., 2019; Goodman, 2016; van de Schoot et al., 2021)

Sumário para Distribuições Probabilísticas

2.1 Leituras Recomendadas

2.2 Distribuições Discretas

2.2.1 Uniforme Discreta

2.2.2 Bernoulli

2.2.3 Binomial

2.2.4 Poisson

2.2.5 Binomial Negativa

2.3 Distribuições Contínuas

2.3.1 Uniforme Contínua

2.3.2 Normal

2.3.3 Log-Normal

2.3.4 Exponencial

2.3.5 t de Student

2.3.6 Beta

Distribuições Probabilísticas - Leituras Recomendadas

- Dekking et al. (2010)
  - Capítulo 4: Discrete random variables
  - Capítulo 5: Continuous random variables

- Betancourt (2019)

Distribuições Probabilísticas

A estatística Bayesiana usa distribuições probabilísticas como o motor de sua inferência na elaboração dos valores dos parâmetros estimados e suas incertezas.

Imagine que distribuição probabilísticas são pequenas peças de "Lego". Podemos construir o que quisermos com essas pequenas peças. Podemos fazer um castelo, uma casa, uma cidade; literalmente o que quisermos. O mesmo é válido para modelos probabilísticos em estatística Bayesiana. Podemos construir modelos dos mais simples aos mais complexo a partir de distribuições probabilísticas e suas relações entre si.

Distribuições Probabilísticas

Definição (Função de Distribuição de Probabilidade)

Uma função de distribuição de probabilidade é a função matemática que fornece as probabilidades de ocorrência de diferentes resultados possíveis para um experimento. É uma descrição matemática de um fenômeno aleatório em termos de seu espaço amostral e as probabilidades de eventos (subconjuntos do espaço amostral).

$$P(X) : X \to \mathbb{R} \in [0, 1]$$

Para variáveis discretas chamamos de "massa" e para variáveis contínuas chamamos de "densidade".

Notação Matemática

Geralmente usamos a notação

$$X \sim \text{Dist}(\theta_1, \theta_2, \dots)$$

Onde:

- X: variável
- Dist: é o nome da distribuição
- $\theta_1, \theta_2, \dots$: os parâmetros que definem como a distribuição se comporta.

Toda distribuição probabilística pode ser "parameterizada" ao especificarmos parâmetros que permitem moldarmos alguns aspectos da distribuição para algum fim específico.

Função Distribuição de Probabilidade

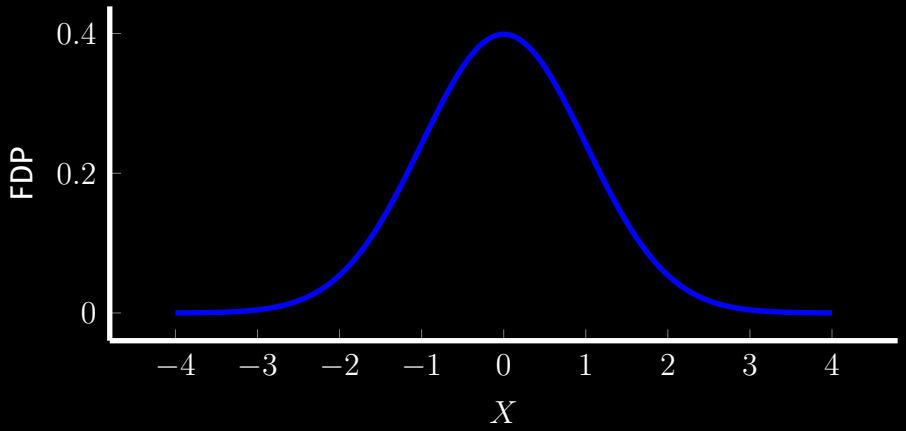

Distribuições Probabilísticas

Definição (Função de Distribuição Cumulativa)

A função de distribuição cumulativa (cumulative distribution function - CDF) de uma variável aleatória X avaliada em x é a probabilidade que X tomará valores menores ou iguais à x:

$$\text{CDF} = P(X \leq x)$$

Função de Distribuição Cumulativa

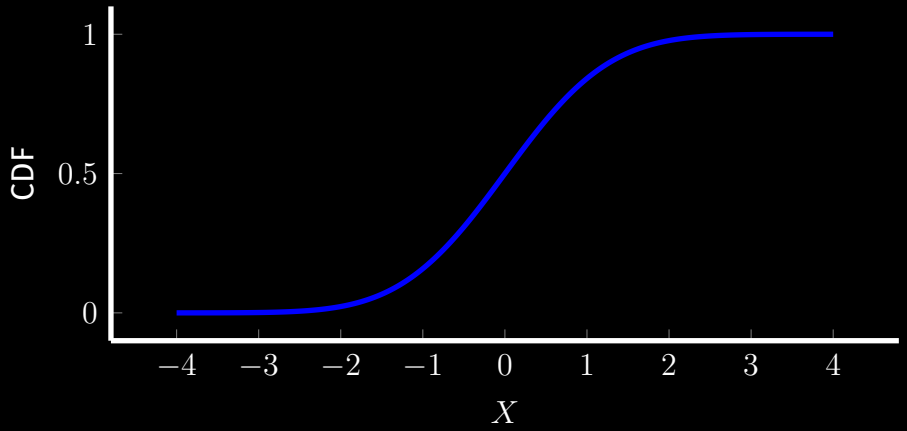

Distribuições Discretas

Definição (Distribuição de Probabilidade Discreta)

Distribuições de probabilidade discretas são aquelas que os resultados são números discretos: $-N, \ldots, -2, 1, 0, 1, 2, \ldots, N$ *e* $N \in \mathbb{Z}$*. Em distribuições discretas chamamos a probabilidade de uma distribuição tomar certos valores como "massa". A função massa de probabilidade FMP é a função que especifica a probabilidade da variável aleatória* X *tomar o valor* x*:*

$$\text{FMP}(x) = P(X = x)$$

Uniforme Discreta

A distribuição uniforme discreta é uma distribuição de probabilidade simétrica em que um número finito de valores são igualmente prováveis de serem observados. Cada um dos n valores tem probabilidade igual $\frac{1}{n}$.

A distribuição uniforme discreta possui dois parâmetros e sua notação é Unif(a, b):

- Limite Inferior (a)
- Limite Superior (b)

Exemplo: Um dado.

Uniforme Discreta

$$\text{Unif}(a,b) = f(x,a,b) = \frac{1}{b-a+1} \quad \text{para } a \leq x \leq b \text{ e } x \in \{a, a+1, \ldots, b-1, b\}$$

Uniforme Discreta

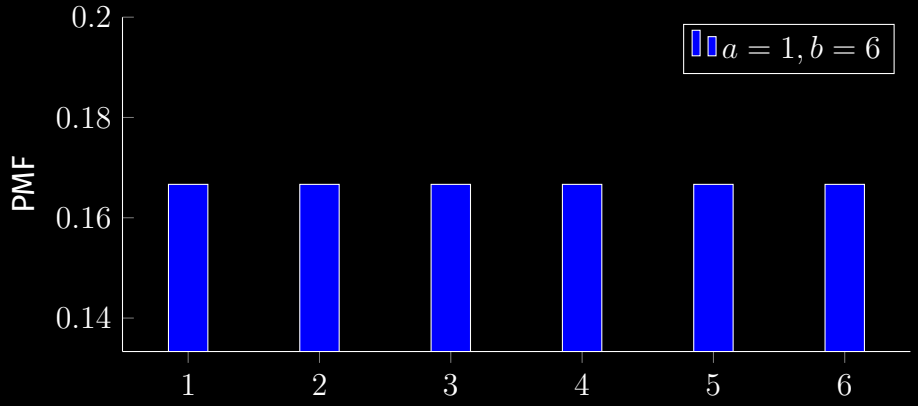

Bernoulli

A distribuição de Bernoulli descreve um evento binário de um sucesso de um experimento. Geralmente representamos 0 como falha e 1 como sucesso, então o resultado de uma distribuição de Bernoulli é uma variável binária $Y \in \{0, 1\}$.

A distribuição de Bernoulli é muito usada para modelar resultados discretos binários no qual só há dois possíveis resultados.

A distribuição de Bernoulli possui apenas um único paramêtro e sua notação é Bernoulli(p):

- Probabilidade de Sucesso (p)

Exemplo: Se o paciente sobreviveu ou morreu ou se o cliente conclui sua compra ou não.

Bernoulli

$$\text{Bernoulli}(p) = f(x,p) = p^x(1-p)^{1-x} \quad \text{para } x \in \{0,1\}$$

Bernoulli

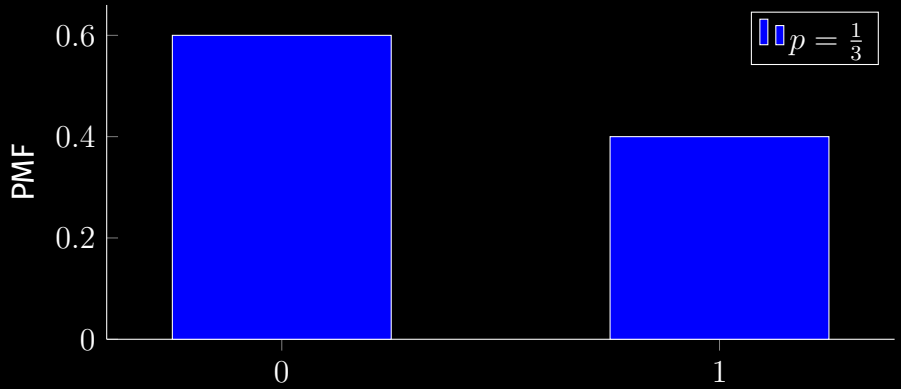

Binomial

A distribuição binomial descreve um evento do número de sucessos em uma sequência de n experimentos independentes, cada um fazendo uma pergunta sim-não com probabilidade de sucesso p. Note que a distribuição de Bernoulli é um caso especial da distribuição binomial no qual o número de experimentos é 1.

A distribuição binomial possui dois parâmetros e sua notação é Bin(n, p) ou Binomial(n, p):

- Número de Experimentos (n)
- Probabilidade de Sucessos (p)

Exemplo: quantidade de caras em 5 lançamentos de uma moeda.

Binomial

$$\text{Binomial}(n,p) = f(x,n,p) = \binom{n}{x} p^x (1-p)^{n-x} \quad \text{para } x \in \{0,1,\ldots,n\}$$

Binomial

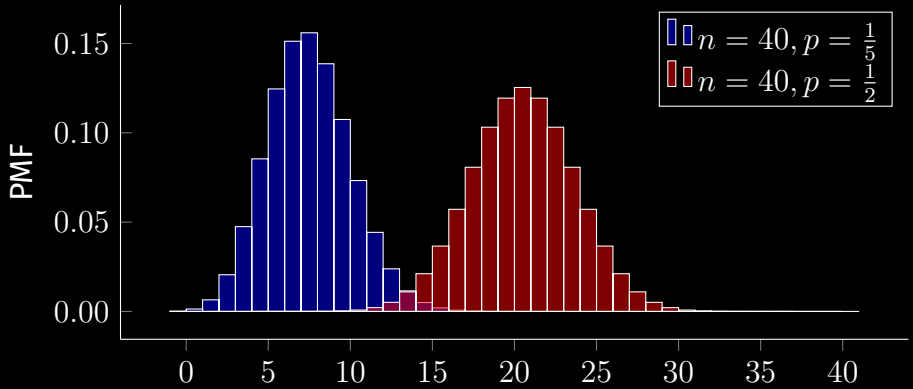
PMF
0.15
0.10
0.05
0.00
0
5
10
15
20
25
30
35
40
$n = 40, p = \frac{1}{5}$
$n = 40, p = \frac{1}{2}$

Poisson

A distribuição Poisson expressa a probabilidade de um determinado número de eventos ocorrerem em um intervalo fixo de tempo ou espaço se esses eventos ocorrerem com uma taxa média constante conhecida e independentemente do tempo desde o último evento. A distribuição de Poisson também pode ser usada para o número de eventos em outros intervalos especificados, como distância, área ou volume.

A distribuição Poisson possui um parâmetro e sua notação é Poisson(λ):

- Taxa (λ)

Exemplo: Quantidade de e-mails que você recebe diariamente.
Quantidade de buracos que você encontra na rua.

Poisson

$$\text{Poisson}(\lambda) = f(x, \lambda) = \frac{\lambda^x e^{-\lambda}}{x!} \quad \text{para } \lambda > 0$$

Poisson

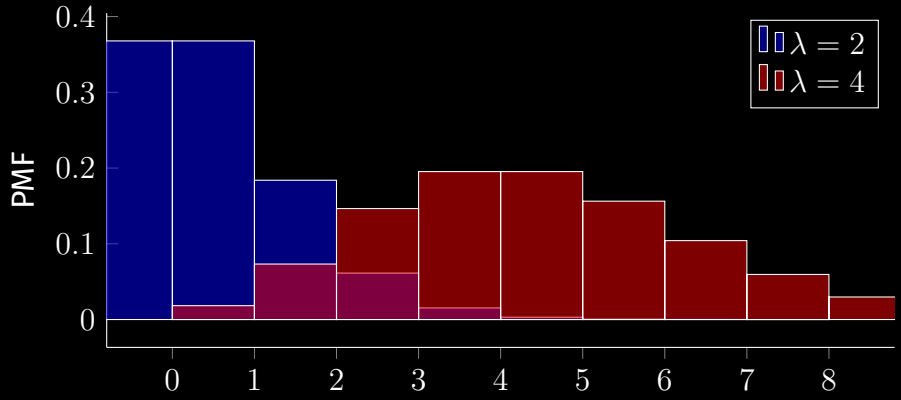

Binomial Negativa[20]

A distribuição binomial negativa descreve um evento do número de sucessos em uma sequência de n experimentos independentes, cada um fazendo uma pergunta sim-não com probabilidade p até que se obtenha k sucessos. Note que ela se torna idêntica à distribuição de Poisson quando no limite de $k \to \infty$. Isto faz com que seja uma opção robusta para substituir uma distribuição de Poisson para modelar fenômenos com uma *superdispersão* (variação nos dados excedente ao esperado).

A distribuição negativa binomial possui dois parâmetros e sua notação é Binomial Negativa(k, p):

- Número de Sucessos (k)
- Probabilidade de Sucessos (p)

Exemplo: Contagem anual de ciclones tropicais.

[20] Qualquer fenômeno que pode ser modelo com uma distribuição de Poisson, pode ser modelo com uma distribuição binomial negativa (Gelman et al., 2013; Gelman, Hill et al., 2020).

Binomial Negativa

$$\text{Binomial Negativa}(k,p) = f(x,k,p) \quad = \binom{x+k-1}{k-1} p^x (1-p)^k$$

para $x \in \{0, 1, \ldots, n\}$

Binomial Negativa

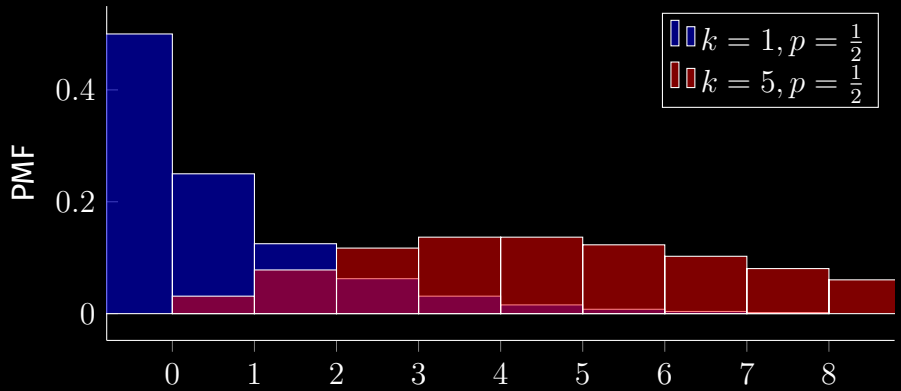

Distribuições Contínuas

Definição (Distribuição de Probabilidade Contínua)

Distribuições de probabilidade contínuas são aquelas que os resultados são valores em uma faixa contínua (também chamados de número reais): $(-\infty, +\infty) \in \mathbb{R}$. Em distribuições contínuas chamamos a probabilidade de uma distribuição tomar certos valores como "densidade". Como estamos falando sobre números reais não conseguimos obter a probabilidade de uma variável aleatória X tomar o valor de x. Isto sempre será 0, pois não há como especificar um valor exato de x. x vive na linha dos números reais, portanto, precisamos especificar a probabilidade de X tomar valores em um ***intervalo*** *$[a, b]$. A função densidade de probabilidade FDP é definida como:*

$$\textit{FDP}(x) = P(a \leq X \leq b) = \int_a^b f(x)dx$$

Uniforme Contínua

A distribuição uniforme contínua é uma distribuição de probabilidade simétrica em que um número infinito de intervalos de valores são igualmente prováveis de serem observados. Cada um dos n infinitos intervalos valores tem probabilidade igual $\frac{1}{n}$.

A distribuição uniforme contínua possui dois parâmetros e sua notação é Unif(a, b):

- Limite Inferior (a)
- Limite Superior (b)

Uniforme Contínua

$$\text{Unif}(a,b) = f(x,a,b) = \frac{1}{b-a} \quad \text{para } a \leq x \leq b \text{ e } x \in [a,b]$$

Uniforme Contínua

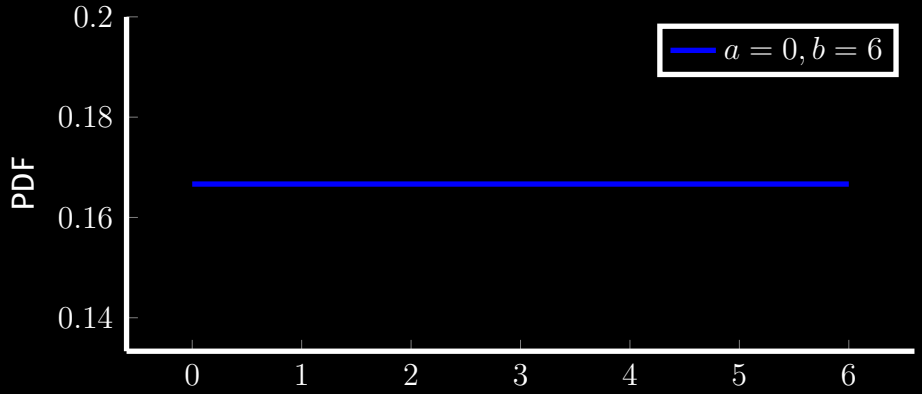

Normal

Essa distribuição geralmente é usada nas ciências sociais e naturais para representar variáveis contínuas na qual as suas distribuições não são conhecidas. Esse pressuposto é por conta do teorema do limite central. O teorema do limite central afirma que, em algumas condições, a média de muitas amostras (observações) de uma variável aleatória com média e variância finitas é ela própria uma variável aleatória cuja distribuição converge para uma distribuição normal à medida que o número de amostras aumenta.

Portanto, as quantidades físicas que se espera sejam a soma de muitos processos independentes (como erros de medição) muitas vezes têm distribuições que são quase normais.

Normal

A distribuição normal possui dois parâmetros e sua notação é Normal(μ, σ^2) ou N(μ, σ^2):

- Média (μ): média da distribuição e também a moda e a mediana
- Desvio Padrão (σ) (às vezes também parametrizada com a variância σ^2): é uma medida de dispersão das observações em relação à média

Exemplo: Altura, Peso etc.

Normal[21]

$$\text{Normal}(\mu, \sigma) = f(x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad \text{para } \sigma > 0$$

[21] Veja como a distribuição Normal foi derivada a partir da distribuição binomial nos Slides de Backup no final dessa apresentação

Normal

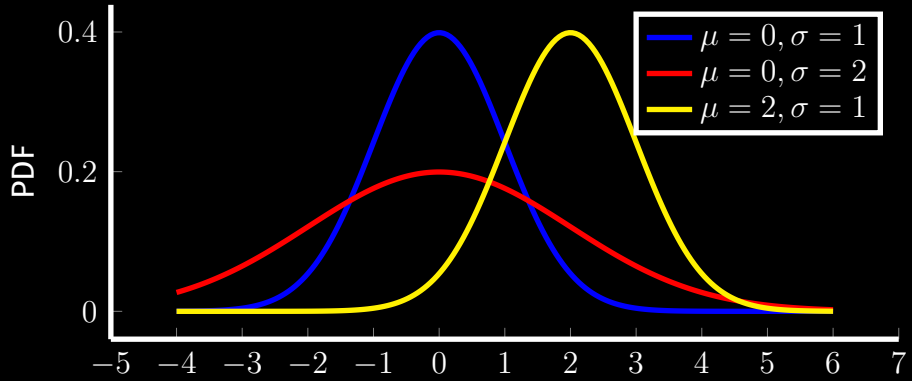

Log-Normal

A distribuição Log-normal é uma distribuição de probabilidade contínua de uma variável aleatória cujo logaritmo é normalmente distribuído. Assim, se a variável aleatória X for distribuída normalmente por $\log$ natural ($\ln$), então $Y = \ln(X)$ terá uma distribuição normal.

Uma variável aleatória com distribuição logarítmica aceita apenas valores reais positivos. É um modelo conveniente e útil para medições em ciências exatas e de engenharia, bem como medicina, economia e outros campos, por ex. para energias, concentrações, comprimentos, retornos financeiros e outros valores.

Um processo log-normal é a realização estatística do produto multiplicativo de muitas variáveis aleatórias independentes, cada uma das quais positiva.

Log-Normal

A distribuição log-normal possui dois parâmetros e sua notação é Log-Normal(μ, σ^2):

- Média (μ): média do logaritmo natural ($\ln$) da distribuição
- Desvio Padrão (σ): a variância do logaritmo natural da distribuição (σ^2) é uma medida de dispersão das observações em relação à média

Log-Normal

$$\text{Log-Normal}(\mu, \sigma) = f(x, \mu, \sigma) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\left(\frac{(\ln(x)-\mu)^2}{2\sigma^2}\right)} \quad \text{para } \sigma > 0$$

Log-Normal

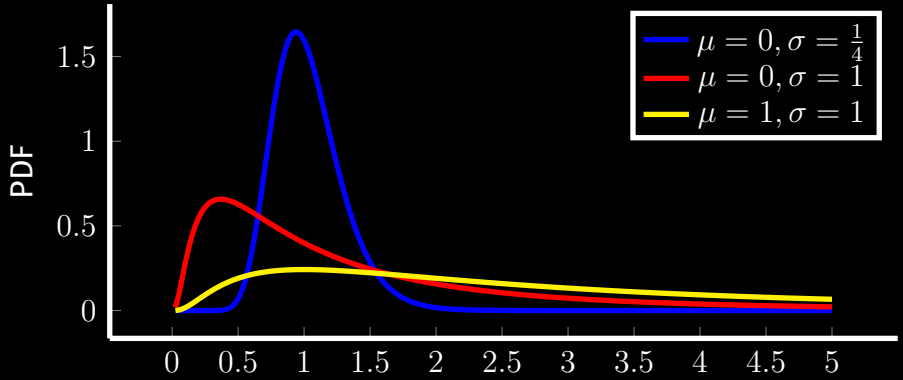
PDF
1.5
1
0.5
0
0
0.5
1
1.5
2
2.5
3
3.5
4
4.5
5
$\mu = 0, \sigma = \frac{1}{4}$
$\mu = 0, \sigma = 1$
$\mu = 1, \sigma = 1$

Exponencial

A distribuição exponencial é a distribuição de probabilidade do tempo entre eventos que ocorrem de forma contínua e independente a uma taxa média constante.

A distribuição exponencial possui um parâmetro e sua notação é Exp(λ):

- Taxa (λ)

Exemplo: Quanto tempo até o próximo terremoto. Quanto tempo até o próximo ônibus.

Exponencial

$$\text{Exp}(\lambda) = f(x, \lambda) = \lambda e^{-\lambda x} \quad \text{para } \lambda > 0$$

Exponencial

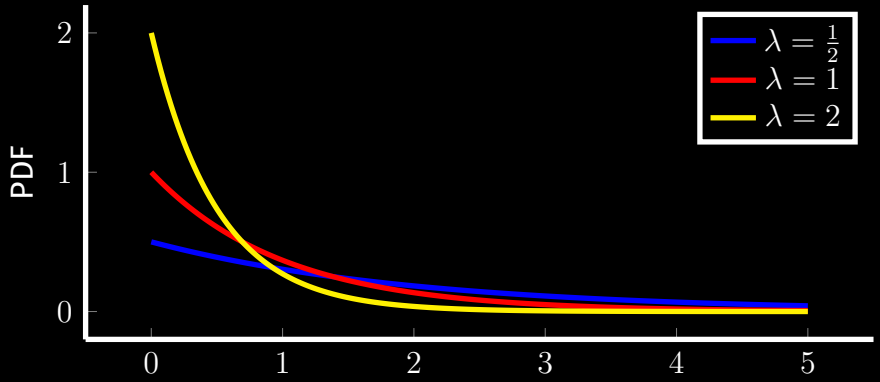

t de Student

A distribuição t de Student surge ao estimar a média de uma população normalmente distribuída em situações onde o tamanho da amostra é pequeno e o desvio padrão da população é desconhecido[22].

Se tomarmos uma amostra de n observações de uma distribuição normal, então a distribuição t com $\nu = n - 1$ graus de liberdade pode ser definida como a distribuição da localização da média da amostra em relação à média verdadeira, dividida pela desvio padrão da amostra, após multiplicar pelo termo padronizador $\sqrt{n}$.

A distribuição t é simétrica e em forma de sino, como a distribuição normal, mas tem caudas mais longas, o que significa que é mais propensa a produzir valores que estão longe de sua média.

[22] Daqui que vem o tal do teste t de Student

t de Student

A distribuição t de Student possui um parâmetro e sua notação é Student(ν):

- Graus de Liberdade (ν): controla o quanto ela se assemelha com uma distribuição normal

Exemplo: Uma base de dados cheia de outliers.

t de Student

$$\text{Student}(\nu) = f(x,\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)}\left(1+\frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} \quad \text{para } \nu \geq 1$$

t de Student

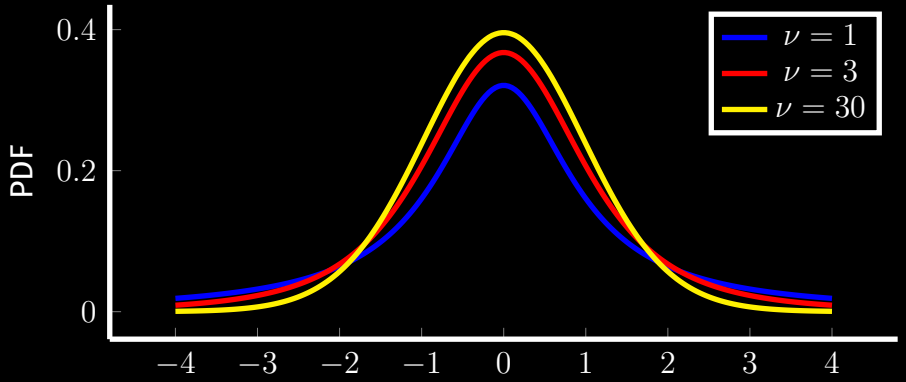

Beta

A distribuição beta é uma escolha natural para modelar qualquer coisa que seja restrita a valores entre 0 e 1. Portanto, é uma boa candidata para probabilidades e proporções.

A distribuição beta possui dois parâmetros e sua notação é Beta(α, β):

- Parâmetro de Forma (α ou às vezes a): controla o quanto a forma é deslocada para próximo de 1
- Parâmetro de Forma (β ou às vezes b): controla o quanto a forma é deslocada para próximo de 0

Exemplo: Um jogador de basquete já marcou 5 lances livres e errou 3 em um total de 8 tentativas - Beta$(3, 5)$

Beta

$$\text{Beta}(\alpha, \beta) = f(x, \alpha, \beta) \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}} \quad \text{para } \alpha, \beta > 0 \text{ e } x \in [0, 1]$$

Beta

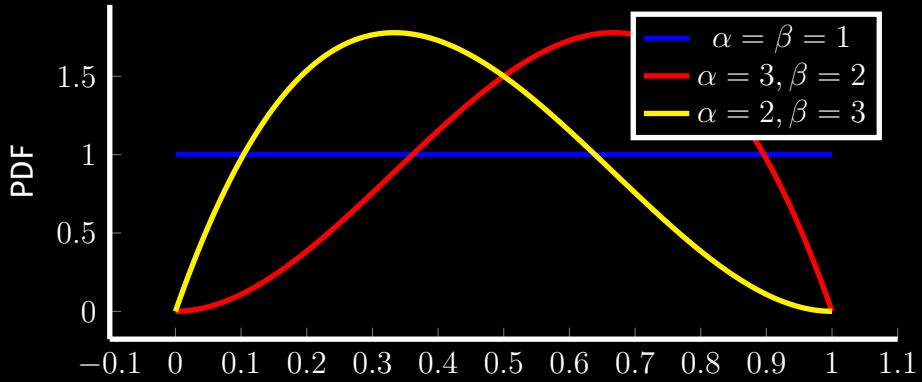
PDF
1.5
1
0.5
0
−0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
1.1
$\alpha = \beta = 1$
$\alpha = 3, \beta = 2$
$\alpha = 2, \beta = 3$

Sumário para rstanarm e brms

3.1 Leituras Recomendadas
3.2 Ecosistema Stan
3.2.1 Interfaces Oficiais
3.2.2 Pacotes
3.3 Especificação de Modelos com Fórmulas
3.4 Funções de Verossimilhança com family
3.5 rstanarm
3.5.1 Modelos do rstanarm
3.5.2 Visualizações do rstanarm
3.5.3 Otimizações do rstanarm
3.6 brms
3.6.1 Modelos do brms
3.6.2 Visualizações do brms
3.6.3 Otimizações do brms

`rstanarm` e `brms` - Leituras Recomendadas[23]

- Vinheta e Manual do `rstanarm` de Goodrich et al. (2020)
- Vinheta e Manual do `brms` de Bürkner (2017)
- Tutorial de `rstanarm` de Muth et al. (2018)
- Tutorial de `brms` de Bürkner (2018)
- *Workflow* Bayesiano de Gelman, Vehtari et al. (2020)
- *Workflow* Visual Bayesiano de Gabry et al. (2019)
- Vinheta e Manual do `bayesplot` Gabry e Mahr (2021)

[23] `rstanarm` - http://mc-stan.org/rstanarm/ e `brms` - https://paul-buerkner.github.io/brms/

O que é Stan

Stan (Carpenter et al., 2017) é uma **plataforma para modelagem e computação estatística de alto desempenho**. Milhares de usuários contam com Stan para modelagem estatística, análise de dados e previsão nas ciências sociais, biológicas e físicas, engenharia e negócios.

Interfaces do Stan

- R: RStan e CmdStanR
- Python: PyStan e CmdStanPy
- Shell (Linha de Comando): CmdStan
- Julia: Stan.jl
- Scala: ScalaStan
- ~~Matlab~~: ~~MatlabStan~~
- ~~Stata~~: ~~StataStan~~
- ~~Mathematica~~: ~~MathematicaStan~~

Interfaces Amigáveis do Stan

Somente para R

- `rstanarm` (Goodrich et al., 2020): ajuda o usuário a especificar modelos usando a sintaxe familiar de fórmulas do R.
- `brms` (Bürkner, 2017): similar ao `rstanarm` pois usa a sintaxe familiar de fórmulas do R, mas dá maior flexibilidade na especificação de modelos mais complexos.

Código Stan

```
data {
  int<lower=0> N;
  vector[N] x1;
  vector[N] x2;
  vector[N] y;
}
parameters {
  real alpha;
  vector[2] beta;
  real<lower=0> sigma;
}
model {
  sigma ~ cauchy(0, 2.5);
  y ~ normal(alpha + beta[1] * x1 + beta[2] * x2, sigma);
}
```

`rstanarm` versus `brms`

Para remediar essa barreira de acesso ao `Stan`, temos interfaces abstratas que interpretam a intenção do usuário e lidam com a parte mais *obral* de codificação:

- `rstanarm` todos os modelos são pré-compilados e `brms` não possui os modelos pré-compilados então os modelos devem ser todos compilados antes de serem rodados
- Como `brms` compila os modelos conforme a especificação do usuário, ele pode criar modelos um pouco mais eficientes que o `rstanarm`
- `brms` dá maior poder e flexibilidade ao usuário na especificação de funções de verossimilhança e também permite modelos mais complexos que o `rstanarm`

Pacotes R

- `bayesplot` – visualização
- `loo` – seleção de modelos com LOO-CV
- `projpred` – seleção de variáveis
- `prophet` – previsão de séries temporais
- `varstan` – modelos *Vector Auto-Regressive* (VAR)
- `blavaan` – *Structural Equation Modeling* (SEM)
- `lgpr` – *Longitudinal Gaussian Process Regression* (LGPR)
- `bayesforecast` – previsão de séries temporais
- `baggr` – meta-análise
- `CausalQueries` – modelos binários causais

Stan[24] na Scopus[25]

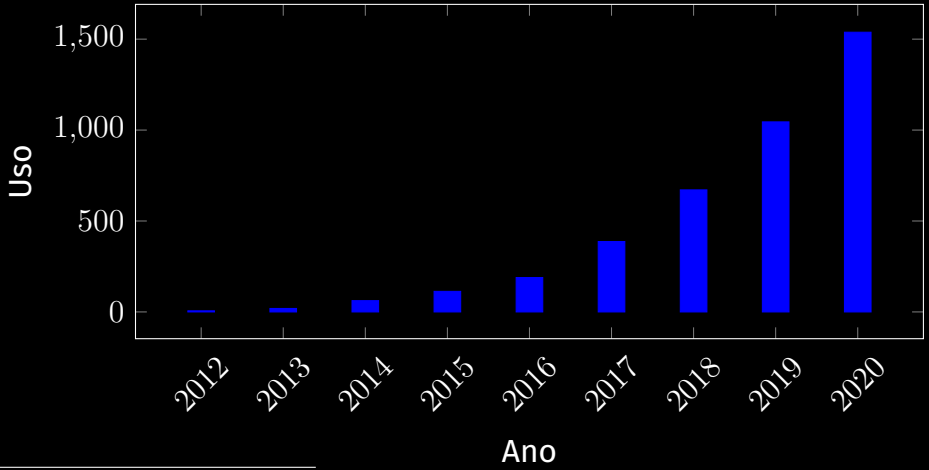

[24] foi lançado em 2012

[25] veja as buscas Scopus nos Slides de Backup no final dessa apresentação

Stan[26][27]

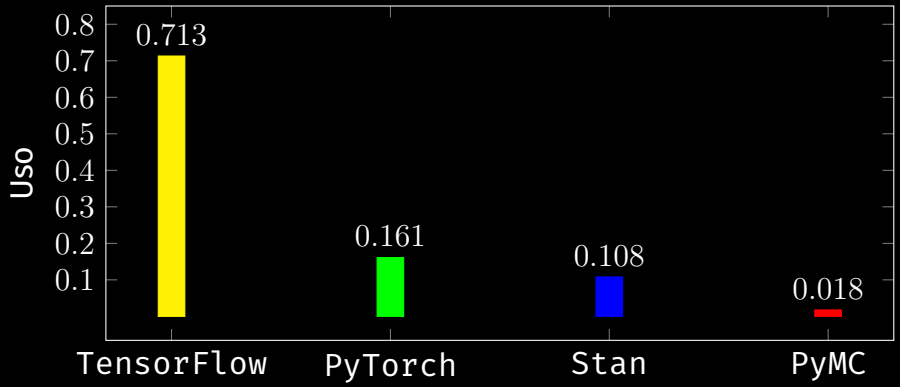

[26] baseado no reporte anual do Breck Baldwin para a NUMFocus

[27] veja as buscas Scopus nos Slides de Backup no final dessa apresentação

Especificação de Modelos com Fórmulas

Todos os modelos especificados pelo `rstanarm` e `brms` usam uma fórmula com a seguinte síntaxe:

```
dependente ~ independente_1 + independente_2 + ...
```

Especificação de Modelos com Fórmulas

Moderações?! Sem problema:

```
dependente ~ independente_1 * moderadora + independente_2 * moderadora + ...
```

Funções de Verossimilhança com `family`

Todo modelo especificado pelo `rstanarm` e `brms` devem especificar qual família da função de verossimilhança (`family`) respectivamente com a função de ligação (`link`) que fará o mapeamento dos parâmetros condicionados nos dados para a variável dependente[28].

[28] caso o usuário não designe nenhum valor para esses dois parâmetros, `rstanarm` e `brms` usarão a verossimilhança Gaussiana (`family = gaussian`) e a função de identidade como função de ligação (`link = "identity"`)

Funções de Verossimilhança com `family`

- Gaussiana – `family = gaussian` – `link = "identity"`
- Log-Normal – `family = lognormal` – `link = "log"`
- Binomial – `family = binomial` – `link = "logit"`
- Poisson – `family = poisson` – `link = "log"`
- Binomial Negativa – `family = negbinomial` – `link = "log"`
- t de Student – `family = student` – `link = "identity"`
- Exponencial – `family = exponential` – `link = "log"`

rstanarm[29]

O rstanarm é a porta de entrada para estatística Bayesiana com Stan.

O nome rstanarm é:

- r: pacote para R
- stan: usa a linguagem probabilística Stan
- arm: acrônimo para *Applied Regression Modeling*

[29] Goodrich et al. (2020)

Modelos do `rstanarm`[30]

- `stan_glm()` – modelos lineares generalizados (***g**eneralized **l**inear **m**odel*)
- `stan_lm()` – modelos lineares regularizados (***l**inear **m**odel)*
- `stan_aov()` – modelo ANOVA (***an**alysis **of va**riance*)
- `stan_glmer()` - modelos linares generalizados multiníveis
- `stan_lmer()` – modelos linares regularizados multiníveis
- `stan_jm()` – modelos longitudinais e de sobrevivência
- `stan_nlmer()` – modelos não-lineares multiníveis (***n**on-**l**inear **m**odel*)
- `stan_polr()` – modelos ordinais
- `stan_gamm4()` – modelos aditivos linares multiníveis

[30] Neste curso usaremos apenas `stan_glm` e `stan_glmer`, mas saiba que você possui uma vasta categoria de modelos Bayesianos à disposição

Sumário para Priors

4.1 Leituras Recomendadas

Priors - Leituras Recomendadas

- Gelman et al. (2013):
  - Capítulo 2: Single-parameter models
  - Capítulo 3: Introduction to multiparameter models

- McElreath (2020) - Capítulo 4: Geocentric Models

- van de Schoot et al. (2021)

- Storopoli (2021) - Priors

Sumário para Markov Chain Monte Carlo - MCMC

5.1 Leituras Recomendadas
5.2 Por quê Precisamos de MCMC?
5.3 Algoritmos de MCMC
5.3.1 Metropolis
5.3.2 Metropolis-Hastings
5.3.3 As Limitações de Metropolis e Metropolis-Hastings
5.3.4 Gibbs
5.3.5 As Limitações de Gibbs
5.3.6 Hamiltonian Monte Carlo (HMC)
5.3.7 No-U-Turn-Sampler (NUTS)
5.3.8 As Limitações de HMC e NUTS
5.4 Convergência de Correntes Markov
5.4.1 Métricas de Convergência
5.4.2 Visualizações de Convergência
5.4.3 O que fazer se Correntes Markov não Convergirem

Markov Chain Monte Carlo - MCMC - Leituras Recomendadas

- Gelman et al. (2013)
  - Capítulo 10: Introduction to Bayesian computation
  - Capítulo 11: Basics of Markov chain simulation
  - Capítulo 12: Computationally efficient Markov chain simulation
- McElreath (2020) - Capítulo 9: Markov Chain Monte Carlo
- Neal (2011)
- Betancourt (2017)
- Gelman, Hill et al. (2020) - Capítulo 22, Seção 22.8: Computational efficiency
- Storopoli (2021) - Markov Chain Monte Carlo
- Chib e Greenberg (1995)
- Casella e George (1992)

Algoritmo de Metropolis[31]

Algoritmo 1: Metropolis

Defina um ponto inicial $\boldsymbol{\theta}^{(0)} \in \mathbb{R}^p$ do qual $P\left(\boldsymbol{\theta}^{(0)} \mid \boldsymbol{y}\right) > 0$

para $t = 1, 2, \ldots$

Amostra uma proposta $\boldsymbol{\theta}^{(*)}$ de uma distribuição de propostas no tempo t, $J_t\left(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(t-1)}\right)$

Como regra de aceitação/rejeição calcule a proporção das probabilidades: $r = \frac{P\left(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{y}\right)}{P\left(\boldsymbol{\theta}^{(t-1)} \mid \boldsymbol{y}\right)}$

Designe: $\boldsymbol{\theta}^{(t)} = \begin{cases} \boldsymbol{\theta}^{(*)} & \text{com probabilidade } \min(r, 1) \\ \boldsymbol{\theta}^{(t-1)} & \text{caso contrário} \end{cases}$

[31] Metropolis et al. (1953)

Intuição Visual de Metropolis

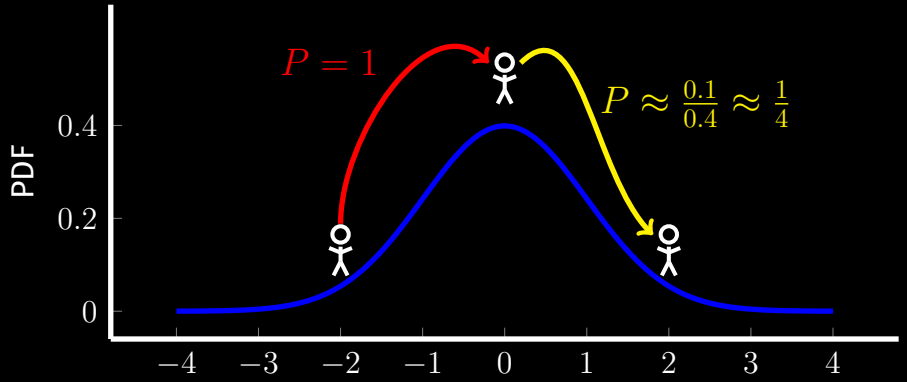

Algoritmo de Metropolis - Hastings[32]

Veja Metropolis em ação no `chi-feng/mcmc-demo`

Algoritmo 2: Metropolis-Hastings

Defina um ponto inicial $\boldsymbol{\theta}^{(0)} \in \mathbb{R}^p$ do qual $P\left(\boldsymbol{\theta}^{(0)} \mid \boldsymbol{y}\right) > 0$

para $t = 1, 2, \ldots$

Amostra uma proposta $\boldsymbol{\theta}^{(*)}$ de uma distribuição de propostas no tempo t, $J_t\left(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(t-1)}\right)$

Como regra de aceitação/rejeição calcule a proporção das probabilidades: $r = \dfrac{\frac{P\left(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{y}\right)}{J_t\left(\boldsymbol{\theta}^{(*)} \mid \boldsymbol{\theta}^{(t-1)}\right)}}{\frac{P\left(\boldsymbol{\theta}^{(t-1)} \mid \boldsymbol{y}\right)}{J_t\left(\boldsymbol{\theta}^{(t-1)} \mid \boldsymbol{\theta}^{(*)}\right)}}$

Designe: $\boldsymbol{\theta}^{(t)} = \begin{cases} \boldsymbol{\theta}^{(*)} & \text{com probabilidade } \min(r, 1) \\ \boldsymbol{\theta}^{(t-1)} & \text{caso contrário} \end{cases}$

[32] Hastings (1970)

Algoritmo de Gibbs[33]

Veja Gibbs em ação no `chi-feng/mcmc-demo`

Algoritmo 3: Gibbs

Defina um ponto inicial $\boldsymbol{\theta}^{(0)} \in \mathbb{R}^p$ do qual $P\left(\boldsymbol{\theta}^{(0)} \mid \boldsymbol{y}\right) > 0$

para $t = 1, 2, \ldots$

Designe: $\boldsymbol{\theta}^{(t)} = \begin{cases} \theta_1^{(t)} & \sim P\left(\theta_1 \mid \theta_2^{(0)}, \ldots, \theta_p^{(0)}\right) \\ \theta_2^{(t)} & \sim P\left(\theta_2 \mid \theta_1^{(t-1)}, \ldots, \theta_p^{(0)}\right) \\ & \vdots \\ \theta_p^{(t)} & \sim P\left(\theta_p \mid \theta_1^{(t-1)}, \ldots, \theta_{p-1}^{(t-1)}\right) \end{cases}$

[33] Geman e Geman (1984)

Algoritmo de HMC[34]

Veja HMC em ação no `chi-feng/mcmc-demo`

Algoritmo 4: Hamiltonian Monte Carlo (HMC)

Defina um ponto inicial $\boldsymbol{\theta}^{(0)} \in \mathbb{R}^p$ do qual $P\left(\boldsymbol{\theta}^{(0)} \mid \boldsymbol{y}\right) > 0$

Amostre $\boldsymbol{\phi}$ de uma Normal$(\mathbf{0}, \mathbf{M})$

Simultaneamente amostre $\boldsymbol{\theta}$ e $\boldsymbol{\phi}$ com L *leapfrog steps* cada um reduzido por um fator ϵ.

para $1, 2, \ldots, L$

> Use o gradiente do $\log$ da posterior de $\boldsymbol{\theta}$ para produzir um *half-step* de $\boldsymbol{\phi}$: $\boldsymbol{\phi} \leftarrow \boldsymbol{\phi} + \frac{1}{2}\epsilon \frac{d \log P(\boldsymbol{\theta}|\boldsymbol{y})}{d\theta}$
>
> Use $\boldsymbol{\phi}$ para atualizar $\boldsymbol{\theta}$: $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \epsilon \mathbf{M}^{-1} \boldsymbol{\phi}$
>
> Novamente use o gradiente de $\boldsymbol{\theta}$ para produzir um *half-step* de $\boldsymbol{\phi}$: $\boldsymbol{\phi} \leftarrow \boldsymbol{\phi} + \frac{1}{2}\epsilon \frac{d \log P(\boldsymbol{\theta}|\boldsymbol{y})}{d\theta}$

Como regra de aceitação/rejeição calcule: $r = \frac{P\left(\boldsymbol{\theta}^{(*)}|\boldsymbol{y}\right) P\left(\boldsymbol{\phi}^{(*)}\right)}{P\left(\boldsymbol{\theta}^{(t-1)}|\boldsymbol{y}\right) P\left(\boldsymbol{\phi}^{(t-1)}\right)}$

Designe: $\boldsymbol{\theta}^{(t)} = \begin{cases} \boldsymbol{\theta}^{(*)} & \text{com probabilidade } \min(r, 1) \\ \boldsymbol{\theta}^{(t-1)} & \text{caso contrário} \end{cases}$

[34] Neal (2011)

Algoritmo de NUTS[35]

Veja NUTS em ação no `chi-feng/mcmc-demo`

Algoritmo 5: No-U-Turn-Sampler (NUTS)

[35] Hoffman e Gelman (2011)

Sumário para Regressão Linear Bayesiana

6.1 Leituras Recomendadas

Regressão Linear Bayesiana - Leituras Recomendadas

- Placeholder

Sumário para Regressão Logística Bayesiana

7.1 Leituras Recomendadas

Regressão Logística Bayesiana - Leituras Recomendadas

- Placeholder

Sumário para Regressão de Poisson Bayesiana

8.1 Leituras Recomendadas

Regressão de Poisson Bayesiana - Leituras Recomendadas

- Placeholder

Sumário para Regressão Robusta Bayesiana

9.1 Leituras Recomendadas

Regressão Robusta Bayesiana - Leituras Recomendadas

- Placeholder

Sumário para Modelos Multiníveis Bayesianos

10.1 Leituras Recomendadas

Modelos Multiníveis Bayesianos - Leituras Recomendadas

- Placeholder

Sumário para Comparação de Modelos

11.1 Leituras Recomendadas

Comparação de Modelos - Leituras Recomendadas

- Placeholder

Referências I

Amrhein, V., Greenland, S. & McShane, B. (2019). Scientists Rise up against Statistical Significance. *Nature*, *567*(7748), 305–307. https://doi.org/10.1038/d41586-019-00857-9

Benjamin, D. J., Berger, J. O., Johannesson, M., Nosek, B. A., Wagenmakers, E.-J., Berk, R., Bollen, K. A., Brembs, B., Brown, L., Camerer, C., Cesarini, D., Chambers, C. D., Clyde, M., Cook, T. D., De Boeck, P., Dienes, Z., Dreber, A., Easwaran, K., Efferson, C., … Johnson, V. E. (2018). Redefine Statistical Significance. *Nature Human Behaviour*, *2*(1), 6–10. https://doi.org/10.1038/s41562-017-0189-z

Bertsekas, D. P. & Tsitsiklis, J. N. (2008, julho 15). *Introduction to Probability, 2nd Edition* (2nd edition). Athena Scientific.

Referências II

Betancourt, M. (2017, janeiro 9). *A Conceptual Introduction to Hamiltonian Monte Carlo*. arXiv: 1701.02434. Obtido 6 novembro 2019, de http://arxiv.org/abs/1701.02434

Betancourt, M. (2019, junho). *Probabilistic Building Blocks* [Beta & Alpha]. Obtido 27 maio 2021, de https://betanalpha.github.io/assets/case_studies/probability_densities.html

Bezanson, J., Edelman, A., Karpinski, S. & Shah, V. B. (2017). Julia: A Fresh Approach to Numerical Computing. *SIAM review*, *59*(1), 65–98.

Bürkner, P.-C. (2017). brms: An R Package for Bayesian Multilevel Models Using Stan. *Journal of Statistical Software*, *80*(1), 1–28. https://doi.org/10.18637/jss.v080.i01

Referências III

Bürkner, P.-C. (2018). Advanced bayesian multilevel modeling with the r package brms. *The R Journal*, *10*(1), 395–411. Obtido 26 fevereiro 2021, de https://journal.r-project.org/archive/2018/RJ-2018-017/index.html

Carpenter, B., Gelman, A., Hoffman, M. D., Lee, D., Goodrich, B., Betancourt, M., Brubaker, M., Guo, J., Li, P. & Riddell, A. (2017). Stan : A Probabilistic Programming Language. *Journal of Statistical Software*, *76*(1). https://doi.org/10.18637/jss.v076.i01

Casella, G. & George, E. (1992). Explaining the Gibbs Sampler [Publisher: Taylor & Francis _eprint: https://www.tandfonline.com/doi/pdf/10.1080/00031305.1992.10475878]. *The American Statistician*, *46*(3), 167–174. https://doi.org/10.1080/00031305.1992.10475878

Referências IV

Chib, S. & Greenberg, E. (1995). Understanding the Metropolis-Hastings Algorithm. *The American Statistician*, *49*(4), 327–335. https://doi.org/10.1080/00031305.1995.10476177

de Finetti, B. (1974). *Theory of Probability* (Volume 1). John Wiley & Sons.

Dekking, F. M., Kraaikamp, C., Lopuhaä, H. P. & Meester, L. E. (2010, outubro 19). *A Modern Introduction to Probability and Statistics: Understanding Why and How*. Springer.

Diaconis, P. & Skyrms, B. (2019, outubro 8). *Ten great ideas about chance* [Google-Books-ID: 68iXDwAAQBAJ]. Princeton University Press.

Fisher, R. A. (1925). *Statistical methods for research workers*. Oliver; Boyd.

Fisher, R. A. (1962). Some Examples of Bayes' Method of the Experimental Determination of Probabilities A Priori. *Journal of the Royal Statistical Society. Series B (Methodological)*, *24*(1), 118–124.

Referências V

Gabry, J. & Mahr, T. (2021). bayesplot: Plotting for Bayesian Models [R package version 1.8.0]. https://mc-stan.org/bayesplot/

Gabry, J., Simpson, D., Vehtari, A., Betancourt, M. & Gelman, A. (2019). Visualization in Bayesian Workflow. *Journal of the Royal Statistical Society: Series A (Statistics in Society)*, *182*(2), 389–402. https://doi.org/10.1111/rssa.12378

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A. & Rubin, D. B. (2013). *Bayesian Data Analysis*. Chapman and Hall/CRC.

Gelman, A., Hill, J. & Vehtari, A. (2020). *Regression and Other Stories*. Cambridge University Press.

Referências VI

Gelman, A., Vehtari, A., Simpson, D., Margossian, C. C., Carpenter, B., Yao, Y., Kennedy, L., Gabry, J., Bürkner, P.-C. & Modrák, M. (2020, novembro 3). *Bayesian Workflow*. arXiv: 2011.01808 [stat]. Obtido 4 fevereiro 2021, de http://arxiv.org/abs/2011.01808

Geman, S. & Geman, D. (1984). Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *PAMI-6*(6), 721–741. https://doi.org/10.1109/TPAMI.1984.4767596

Goodman, S. N. (2016). Aligning Statistical and Scientific Reasoning. *Science*, *352*(6290), 1180–1181. https://doi.org/10.1126/science.aaf5406
59 citations (Semantic Scholar/DOI) [2021-02-13]

Referências VII

Goodrich, B., Gabry, J., Ali, I. & Brilleman, S. (2020). rstanarm: Bayesian applied regression modeling via Stan. [R package version 2.21.1]. https://mc-stan.org/rstanarm

Hastings, W. K. (1970). Monte Carlo Sampling Methods Using Markov Chains and Their Applications. *Biometrika*, *57*(1), 97–109. https://doi.org/10.1093/biomet/57.1.97

Head, M. L., Holman, L., Lanfear, R., Kahn, A. T. & Jennions, M. D. (2015). The extent and consequences of p-hacking in science. *PLoS Biol*, *13*(3), e1002106.

Hoffman, M. D. & Gelman, A. (2011). The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, *15*(1), 1593–1623. http://arxiv.org/abs/1111.4246

Referências VIII

Ioannidis, J. P. A. (2019). What Have We (Not) Learnt from Millions of Scientific Papers with P Values? *The American Statistician*, *73*(sup1), 20–25. https://doi.org/10.1080/00031305.2018.1447512

It's time to talk about ditching statistical significance. (2019). *Nature*, *567*(7748), 283–283. https://doi.org/10.1038/d41586-019-00874-8

Jaynes, E. T. (2003). *Probability Theory: The Logic of Science*. Cambridge university press.

Kolmogorov, A. N. (1933). *Foundations of the Theory of Probability*. Julius Springer.

Kurt, W. (2019, julho 9). *Bayesian Statistics the Fun Way: Understanding Statistics and Probability with Star Wars, LEGO, and Rubber Ducks* (Illustrated edition). No Starch Press.

Referências IX

Lakens, D., Adolfi, F. G., Albers, C. J., Anvari, F., Apps, M. A., Argamon, S. E., Baguley, T., Becker, R. B., Benning, S. D., Bradford, D. E., Buchanan, E. M., Caldwell, A. R., Van Calster, B., Carlsson, R., Chen, S. C., Chung, B., Colling, L. J., Collins, G. S., Crook, Z., ... Zwaan, R. A. (2018). Justify Your Alpha. *Nature Human Behaviour*, *2*(3), 168–171. https://doi.org/10.1038/s41562-018-0311-x

McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. CRC press.

Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H. & Teller, E. (1953). Equation of State Calculations by Fast Computing Machines. *The Journal of Chemical Physics*, *21*(6), 1087–1092. https://doi.org/10.1063/1.1699114

Referências X

Muth, C., Oravecz, Z. & Gabry, J. (2018). User-friendly Bayesian regression modeling: A tutorial with rstanarm and shinystan. *Quantitative Methods for Psychology*, *14*(2), 99–119.

Neal, R. M. (2011). MCMC Using Hamiltonian Dynamics. Em S. Brooks, A. Gelman, G. L. Jones & X.-L. Meng (Eds.), *Handbook of Markov Chain Monte Carlo*.

Neyman, J. (1937). Outline of a theory of statistical estimation based on the classical theory of probability. *Philosophical Transactions of the Royal Society of London. Series A, Mathematical and Physical Sciences*, *236*(767), 333–380.

Perkel, J. M. (2019). Julia: Come for the Syntax, Stay for the Speed. *Nature*, *572*(7767), 141–142. https://doi.org/10.1038/d41586-019-02310-3

Referências XI

Rosnow, R. L. & Rosenthal, R. (1989). Statistical procedures and the justification of knowledge in psychological science. *American Psychologist*, *44*, 1276–1284.

Salvatier, J., Wiecki, T. V. & Fonnesbeck, C. (2016). Probabilistic programming in Python using PyMC3. *PeerJ Computer Science*, *2*, e55.

Storopoli, J. (2021). Estatística Bayesiana com R e Stan. https://storopoli.io/Estatistica-Bayesiana

van de Schoot, R., Depaoli, S., King, R., Kramer, B., Märtens, K., Tadesse, M. G., Vannucci, M., Gelman, A., Veen, D., Willemsen, J. & Yau, C. (2021). Bayesian statistics and modelling. *Nature Reviews Methods Primers*, *1*(1), 1–26. https://doi.org/10.1038/s43586-020-00001-2

Referências XII

Wasserstein, R. L. & Lazar, N. A. (2016). The ASA's Statement on p-Values: Context, Process, and Purpose. *American Statistician*, *70*(2), 129–133. https://doi.org/10.1080/00031305.2016.1154108
2634 citations (Semantic Scholar/DOI) [2021-02-13]

Wasserstein, R. L., Schirm, A. L. & Lazar, N. A. (2019). Moving to a World Beyond "$p < 0.05$". *American Statistician*, *73*, 1–19. https://doi.org/10.1080/00031305.2019.1583913
662 citations (Semantic Scholar/DOI) [2021-02-13]

Como citar esse Conteúdo

Storopoli, J. (2021). Estatística Bayesiana com R e Stan.
https://storopoli.io/Estatistica-Bayesiana

Buscas Scopus do Stan

- Uso Geral na Scopus: `ALL((brms AND burkner) OR (gelman AND hoffman AND stan) OR mc-stan.org OR rstanarm OR pystan OR (rstan AND NOT mit))`

- Uso em Comparação com outras Ferramentas Bayesianas: `REF((gelman AND hoffman AND stan) OR mc-stan.org) AND REF(brms AND burkner) AND REF(pystan) AND REF(rstanarm) AND REF(rstan AND NOT mit)`

- Uso das Ferramentas Bayesians: a busca anterior adicionado de `REF(PyMC3 OR (PyMC* AND fonnesbeck)) AND REF(tensorflow) AND REF(pytorch) AND REF(Keras)`

Simulação Monte Carlo do Problema de Monty Hall em R

```
monty <- function(){
  door_car <- sample(1:3L, 1)
  door_pick <- sample(1:3L, 1)
  door_goats <- setdiff(1:3L, door_car)
  if(door_pick == door_car) {
    door_show <- sample(door_goats, 1)
  } else{
    door_show <- setdiff(door_goats, door_pick)
  }
  door_switch <- setdiff(1:3L, c(door_pick, door_show))[1]
  door_pick <- door_switch
}
wins <- 0
ntrials <- 10000
for (i in 1:ntrials){
  wins <- wins + monty()
}
wins / ntrials
```

Simulação Monte Carlo do Problema de Monty Hall em Julia

```julia
function monty()
  door_car = rand(1:3)
  door_pick = rand(1:3)
  door_goats = setdiff([1;2;3],door_car)
  door_show = door_pick == door_car ? rand(door_goats) : setdiff(door_goats,door_pick)
  door_switch = setdiff([1;2;3], [door_pick; door_show])[1]
  door_pick = door_switch
  return door_pick == door_car
end
ntrials = 10_000
wins = reduce(+, (monty() for i ∈ 1:ntrials))
wins / ntrials
```

Como surgiu a distribuição Normal[36][37]

$$\text{Binomial}(n,k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$n! \approx \sqrt{2\pi n}\left(\frac{n}{e}\right)^n \qquad \text{(Stirling)}$$

$$\lim_{n\to\infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{1}{\sqrt{2\pi npq}} e^{-\frac{(k-np)^2}{2npq}}$$

Sabemos que na binomial: $\mathrm{E} = np$ e $\mathrm{Var} = npq$; logo substituindo E por μ Var por σ^2:

$$\lim_{n\to\infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(k-\mu)^2}{\sigma^2}}$$

[36] Abraham de Moivre em 1738

[37] Uma melhor explanação pode ser encontrada clidando aqui